



MNA Maestría en Inteligencia Artificial Aplicada

Materia: TC5043.10

Procesamiento de lenguaje natural (Gpo 10)

Profesor Titular

Dr. Luis Eduardo Falcón Morales

Profesor Asistente

Yetnalezi Quintas Ruiz

EQUIPO 34

Maricel Parra Osorio | A01793932

Iván Pedraza | A01795371

Iván Pedrero | A01366501

Jorge Pedroza | A01319553

10.3 Actividad: Actividad: modelos LLM y IA en tu lugar de trabajo

Monterrey, Nuevo León, México, 25 de junio de 2024.

Introducción

En la parte final de la asignatura Procesamiento de Lenguaje Natural, llevaremos a cabo la presente actividad que nos permitirá explorar dos modelos de Lenguaje de Aprendizaje Automático (LLM) como ChatGPT 4, y Gemini, y cómo estos pueden ser utilizados para generar ideas innovadoras en nuestras áreas de trabajo.

Implementaremos la técnica de ingeniería de instrucciones (prompt engineering) con el LLM elegido para cada caso. Esta aproximación nos permitirá obtener ideas innovadoras sobre cómo integrar la Inteligencia Artificial en nuestras tareas cotidianas. Nuestro propósito es desarrollar una guía inicial que no solo nos ayude a identificar las áreas de oportunidad para la IA en nuestras empresas, sino que también nos proporcione una hoja de ruta detallada de los pasos necesarios para implementar estas soluciones.

Como cierre de esta actividad, presentaremos un análisis crítico de nuestras conclusiones, evaluando el potencial impacto de estas tecnologías en nuestros respectivos campos y reflexionando sobre las implicaciones más amplias de la integración de la IA en el ámbito laboral.

Desarrollo

A continuación, se detallan las dos dinámicas abordadas para el desarrollo de la actividad.

Temática 1: Desarrollo de escenarios climáticos

1.1 Indicar información de la empresa y su principal giro comercial:

En ERM es la firma consultora más grande del mundo en sostenibilidad, con más de 50 años de experiencia, son el asesor de confianza para integrar soluciones de sostenibilidad., con una experiencia única en negocios y finanzas. Ayuda a las organizaciones líderes a establecer y medir objetivos de sostenibilidad, implementando estrategias profundas y transformaciones empresariales.

1.2 Indicar el área o departamento a la cual pertenece el proyecto/actividad seleccionada

Sustentabilidad Corporativa y Cambio Climático

1.3 Describir claramente en qué consiste cada una de estas actividades.

En el área se trabaja con organizaciones para desarrollar respuestas estratégicas e integrar estrategias de carbono en planes de cero emisiones netas, incluyendo asesoramiento en estrategias y proyectos de mitigación de carbono. Ayuda a los clientes a aprovechar oportunidades a través de la próxima generación de tecnologías diseñadas para descarbonizar sectores clave de la economía. Su experiencia en el análisis, inversión e implementación de tecnologías de bajo carbono de vanguardia respalda la diferenciación en el mercado.

1.4 Indicar con qué otras áreas de la empresa te relacionas o interactúas generalmente.

Se tiene una fuerte interacción con otras áreas como:

- Debita Diligencia (Due Dilligence) en donde se integran aspectos de cumplimiento sobre las operaciones de compra y venta de empresas
- Estrategia y Reporte de Sustentabilidad, en donde se trabaja con la alta administración de los clientes en la definición de sus objetivos estratégicos de sustentabilidad
- Calidad del Aire, en donde se analizan las emisiones de los centros de trabajo de los clientes medidos como Alcance 1.
- Energía y Cambio Climático, en donde se analizan las emisiones de Alcance 2 y los impactos ambientales en los componentes de las cadenas de valor de los clientes
- Implementación de Sistemas, en donde se aterrizan las estrategias definidas y se ejecutan los procesos y habilitación de sistemas para su realización.
- Certificación y Verificación, en donde se realizan las auditorías de certificación tanto de aspectos de cumplimiento, como operativos.

1.5 Descripción de la ingeniería de instrucciones (prompt engineering)

Para abordar la primera temática, hemos optado por utilizar ChatGPT en su versión más avanzada, Microsoft Copilot Pro GPT-4. Esta elección nos permitirá explorar un amplio espectro de aplicaciones de Inteligencia Artificial, enfocándonos específicamente en las siguientes áreas: Machine learning, Deep Learning, Generative AI, Análisis de datos estructurados y no estructurados, Visión Computacional, y finalmente Procesamiento de Lenguaje Natural (NLP).

En el diseño de nuestro enfoque de ingeniería de instrucciones (prompt engineering), hemos adoptado el marco conceptual propuesto por Khan (2023), que identifica cuatro elementos fundamentales en la construcción de prompts efectivos: 1) Instrucción, 2) Contexto, 3) Inyección de datos y 4) indicador de salida. Utilizando la herramienta "ChatGPT Prompt Generator" (Merve. 2024), se le da la instrucción estándar a nuestro prompt:

Quiero que actúes como Consultor Experto en temas ambientales [inyectar contexto] para [inyectar la instrucción específica o datos]. El formato de salida que sea [tipo de formato de salida, que puede ser texto, información tabular, información acotada, etc.].

Considerando que una de las tareas del área es el análisis de tendencia de consumo en los aspectos de tecnologías limpias, se preparó el primer prompt para contestar este requerimiento, incluyendo cómo se puede hacer el uso de ML a esta consulta.

Consulta 1

Quiero que actúes como Consultor Experto en temas ambientales [en el sector industrial del norte de México] para [conocer cómo puedo aplicar Machine Learning en la identificación de tendencias de consumo de tecnologías ecoeficientes en México]. El formato de salida que sea [en lista de bullets].

Respuesta:

Como consultor experto en temas ambientales, te puedo decir que el Machine Learning (ML) puede ser una herramienta muy útil para identificar tendencias de consumo de tecnologías ecoeficientes. Aquí te dejo algunas ideas sobre cómo podrías aplicarlo:

1. **Predicción del consumo energético:** El ML puede ser utilizado para predecir con precisión el consumo de energía¹. Esto puede ser útil para entender cómo y cuándo se usan las tecnologías ecoeficientes.
2. **Análisis de datos estructurados y no estructurados:** El ML es capaz de encontrar patrones en los datos que se le proporcionan². Esto significa que se puede utilizar para analizar una amplia gama de datos, desde imágenes hasta datos estructurados y no estructurados, para identificar tendencias en el consumo de tecnologías ecoeficientes.
3. **Automatización de tareas repetitivas:** El ML puede hacer automáticas las actividades repetitivas, mecánicas o incluso de alta complejidad³. Esto puede ser útil para automatizar el seguimiento del consumo de tecnologías ecoeficientes y liberar tiempo para centrarse en otras tareas.
4. **Personalización de recomendaciones:** El ML puede ayudar a ofrecer experiencias altamente personalizadas². Esto puede ser útil para proporcionar recomendaciones personalizadas sobre qué tecnologías ecoeficientes podrían ser más adecuadas para una empresa o sector específico.

Para aplicar ML en formato tabular, podrías considerar los siguientes pasos:

1. **Recopilación de datos:** Recopila datos sobre el consumo de tecnologías ecoeficientes en el sector industrial del norte de México. Estos datos podrían incluir

información sobre qué tecnologías se están utilizando, cuánta energía están consumiendo, cuándo se están utilizando, etc.

2. **Preprocesamiento de datos:** Limpia y organiza los datos en un formato tabular. Esto podría implicar la eliminación de datos irrelevantes, la gestión de datos faltantes, la codificación de variables categóricas, etc.
3. **Entrenamiento del modelo:** Utiliza un algoritmo de ML para entrenar un modelo en tus datos. El algoritmo que elijas dependerá de la naturaleza de tus datos y del problema que estés tratando de resolver.
4. **Evaluación del modelo:** Evalúa la precisión de tu modelo. Esto podría implicar la utilización de una matriz de confusión, la curva ROC, etc.
5. **Interpretación de los resultados:** Interpreta los resultados de tu modelo para identificar tendencias en el consumo de tecnologías ecoeficientes.

Sector	Tecnología Ecoeficiente	Consumo Promedio	Tendencia
Automotriz	Energía Solar	450 kWh/mes	Aumentando
Manufactura	Reciclaje de Agua	3000 L/día	Estable
Agricultura	Drones para Riego	150 ha/día	Disminuyendo
Minería	Vehículos Eléctricos	200 vehículos	Aumentando

Este es solo un ejemplo y los datos son ficticios, pero te da una idea de cómo se podría presentar la información. Los valores exactos y las tendencias dependerán de los datos reales que se obtengan y del modelo de Machine Learning que se utilice.

Consulta 2

Quiero que actúes como Consultor Experto en temas ambientales [con conocimiento de México y LATAM] para [conocer cuáles son las tendencias más importantes en tecnologías de disminución de carbono]. El formato de salida que sea [tabular].

Respuesta:

Claro, aquí te presento las principales tendencias en tecnologías de disminución de carbono en México y LATAM:

Tendencia	Descripción
Inversión en Energía con Bajas Emisiones de Carbono	La inversión global en la transición a la energía con bajas emisiones de carbono sumó en total 1,100 billones de dólares en 2022¹. Casi todos los sectores alcanzaron niveles récord de inversión en 2022, incluyendo la energía renovable, el almacenamiento de energía, el transporte electrificado, la calefacción electrificada, la captura y almacenamiento de carbono (CCS), el hidrógeno y los materiales sostenibles¹.
Tecnología para Capturar CO2	El Instituto de Materiales Avanzados del Tec de Monterrey desarrolla tecnología para capturar CO2 y transformarlo². Las grandes empresas han emprendido estrategias de descarbonización que plantean reducir la quema de combustibles fósiles en sus procesos de producción y, con ello, disminuir al mínimo sus emisiones de dióxido de carbono (CO2)².
Tecnologías de Transporte Bajas en Carbono	Se está evaluando el impacto ambiental en el ciclo de vida de las tecnologías de transporte en México³. Estas tecnologías pueden contribuir significativamente a la comprensión del potencial de reducción de emisiones de GEI en el sector transporte y la sustentabilidad a largo plazo³.
Reducción de Emisiones de Carbono	México reafirma su compromiso de reducir 22% de GEI y 51% de Carbono Negro (CN) de manera no condicionada⁴. Para aumentar la ambición en los ocho sectores que contribuyen a la reducción de emisiones: Transporte, Generación de Energía Eléctrica, Petróleo y Gas, Residuos, Industria, Residencial y Comercial, Agricultura y Ganadería y Uso de Suelo, Cambio de Uso de Suelo y Silvicultura (USCUSS)⁴.

Consulta 3

Quiero que actúes como Consultor Experto en temas ambientales [con conocimiento de Canadá, Estados Unidos y México] para [conocer cómo implementar modelos de Deep Learning para servicios de mitigación de emisiones que puedo dar en la consultora en la que trabajo]. El formato de salida que sea [bullets].

Claro, aquí te dejo algunos puntos clave sobre cómo implementar modelos de Deep Learning para servicios de mitigación de emisiones en Canadá, Estados Unidos y México:

Canadá:

- El Centro de Excelencia de Metano es una iniciativa conjunta entre Recursos Naturales de Canadá e Innovación, Ciencia y Desarrollo Económico de Canadá. [Este centro se centra en las necesidades de datos y el desarrollo de tecnología para la medición, informe, verificación y mitigación de las emisiones de metano dentro del sector energético¹.](#)
- Un estudio reciente utilizó redes neuronales de memoria a largo plazo (LSTM) para predecir las concentraciones de metano en Alberta, Canadá. [Los resultados indicaron que la inclusión de variables climáticas mejora las capacidades predictivas del modelo LSTM².](#)

Estados Unidos:

- [En el Laboratorio Jefferson, se están utilizando arquitecturas de aprendizaje profundo para modelar simultáneamente las mediciones de radiación en múltiples detectores en respuesta a distribuciones de gradientes arbitrarios³.](#)
- [Un estudio reciente desarrolló cuatro algoritmos de aprendizaje automático para estimar las emisiones de CO2 en los Estados Unidos⁴.](#)

México:

- [México ha lanzado una herramienta que ayudará a monitorear las acciones de mitigación y adaptación en las entidades del país⁵.](#)
- [El Sistema de Comercio de Emisiones \(SCE\) de México es crucial para que el país cumpla con sus compromisos internacionales de reducción de emisiones⁶.](#)

Es importante tener en cuenta que la implementación de modelos de Deep Learning para la mitigación de emisiones requiere un enfoque multidisciplinario que incluya expertos en ciencias ambientales, ingeniería de software y análisis de datos. Además, es esencial mantenerse actualizado con las últimas investigaciones y políticas en este campo para garantizar que los modelos sean precisos y relevantes.

¿Cómo accedo a esa información y cómo lo proceso en modelos de deep learning?

Para acceder a la información y procesarla en modelos de Deep Learning, puedes seguir los siguientes pasos:

1. **Recopilación de datos:** Los modelos de Deep Learning requieren grandes cantidades de datos para entrenarse eficazmente. [Puedes obtener estos datos de diversas fuentes, como bases de datos públicas, APIs, sensores, entre otros¹.](#)
2. **Preprocesamiento de datos:** Los datos recopilados deben ser preprocesados antes de ser alimentados a los modelos de Deep Learning. [Esto puede incluir la limpieza de datos, la normalización, la codificación de etiquetas, entre otros¹.](#)
3. **Selección del modelo:** Debes seleccionar el tipo de modelo de Deep Learning que mejor se adapte a tu problema. [Esto puede ser una red neuronal convolucional \(CNN\) para tareas de visión por computadora, una red neuronal recurrente \(RNN\) para tareas de procesamiento de lenguaje natural, entre otros².](#)
4. **Entrenamiento del modelo:** Una vez que tienes tus datos preprocesados y tu modelo seleccionado, puedes comenzar a entrenar tu modelo. [Esto implica alimentar tus datos al modelo y ajustar los parámetros del modelo para minimizar el error¹.](#)
5. **Evaluación del modelo:** Después de entrenar tu modelo, debes evaluar su rendimiento utilizando un conjunto de datos de prueba¹.
6. **Implementación del modelo:** Una vez que estés satisfecho con el rendimiento de tu modelo, puedes implementarlo para realizar predicciones en datos nuevos¹.

Es importante recordar que el Deep Learning es un campo complejo que requiere una comprensión sólida de los conceptos de aprendizaje automático. Existen numerosos recursos en línea y cursos que pueden ayudarte a adquirir estos conocimientos.

Comentarios finales

- **Aplicación de IA en el Análisis de Sostenibilidad:** La inteligencia artificial, especialmente los modelos de Machine Learning (ML) y Deep Learning, proporciona herramientas esenciales para mejorar la precisión en la predicción de patrones de consumo energético y emisiones de carbono. Estas técnicas permiten analizar grandes volúmenes de datos y capturar relaciones complejas que los métodos tradicionales no pueden detectar.
- **Variedad de Modelos:** Existe una amplia gama de algoritmos aplicables a la sostenibilidad, desde modelos simples como la regresión lineal hasta técnicas avanzadas como redes neuronales convolucionales (CNN) y redes neuronales de memoria a largo plazo (LSTM). La elección del modelo depende de la naturaleza de los datos y la complejidad del problema a resolver.

- **Automatización de Tareas Repetitivas:** El ML permite automatizar actividades repetitivas y mecánicas, liberando recursos para centrarse en tareas más estratégicas y complejas.
- **Segmentación y Personalización:** La segmentación de datos, mediante técnicas como K-Means Clustering, y la personalización de recomendaciones son pasos fundamentales para ofrecer soluciones específicas y adaptadas a cada organización o sector.
- **Integración de Datos Externos:** La incorporación de datos externos y el análisis de sentimientos a través de NLP (Natural Language Processing) destacan la importancia de considerar un contexto más amplio en las predicciones y estrategias de sostenibilidad.
- **Implementación y Mantenimiento:** La implementación exitosa de modelos de IA en un entorno empresarial requiere la actualización continua de datos, el reentrenamiento regular de los modelos y una interpretación adecuada de los resultados.
- **Adaptación Regional:** La capacidad de adaptar las estrategias de IA a diferentes contextos regionales, como México, LATAM, Canadá y Estados Unidos, es fundamental para el éxito de las iniciativas de mitigación de emisiones y sostenibilidad.

Temática 2: Revenue Management – Estimación de elasticidades.

2.1 Indicar información de la empresa y su principal giro comercial:

- **Nombre de la empresa:** Sigma Alimentos
- **Giro Comercial:** Producción y distribución de alimentos.

2.2 Indicar el área o departamento a la cual pertenece el proyecto/actividad seleccionada.

Área: Revenue Management

2.3 Describir claramente en qué consiste cada una de estas actividades.

Actividad: Estimación/ Calculo de elasticidad de los productos. Dentro del departamento de Revenue Management, la actividad de estimar o calcular la elasticidad de productos es una tarea crucial que implica analizar cómo los cambios en los precios afectan la demanda de los productos o servicios que ofrece la empresa. Esta tarea es fundamental para maximizar los ingresos y asegurar una gestión de precios eficiente.

2.4 Indicar con qué otras áreas de la empresa te relacionas o interactúas generalmente.

Departamento de Marketing: Colaboración esencial para entender las campañas actuales y planificadas, promociones y cambios en la percepción de marca que pueden influir en la demanda y, por tanto, en la elasticidad de los productos.

Departamento de Ventas: Interacción crucial para obtener feedback directo sobre las reacciones del mercado a los cambios de precios.

Departamento de Finanzas: Colaboración para alinear las estrategias de precios con los objetivos financieros globales de la empresa.

2.5 Descripción de la ingeniería de instrucciones (prompt engineering)

Se optó que, para esta segunda temática, se utilizara ChatGPT, en su versión GPT-4o. Asimismo, los temas de IA seleccionados para esta segunda temática buscan abordar las áreas de machine learning, deep learning, datos estructurados y no estructurados.

Consulta 1

- ¿Cómo puede la inteligencia artificial mejorar la precisión en la estimación de la elasticidad de los productos? Haz una respuesta clara, concisa y resumida de tal manera sea entendible.

Respuesta:

La inteligencia artificial puede mejorar la precisión en la estimación de la elasticidad de los productos mediante las siguientes técnicas:

- 2 **Modelos de Machine Learning:** Algoritmos como regresión lineal múltiple y árboles de decisión pueden analizar grandes volúmenes de datos históricos para identificar patrones complejos entre precio y demanda.
- 3 **Redes Neuronales:** Pueden capturar relaciones no lineales y patrones ocultos en los datos, proporcionando estimaciones más precisas.
- 4 **Análisis de Sentimiento:** Utilizando procesamiento de lenguaje natural (NLP) para analizar opiniones y tendencias en redes sociales, se pueden ajustar las estimaciones de elasticidad basadas en la percepción del consumidor.
- 5 **Modelos Bayesianos:** Permiten la actualización continua de estimaciones a medida que se dispone de nuevos datos, proporcionando intervalos de confianza más precisos.
- 6 **Segmentación de Clientes:** Agrupar a los consumidores en segmentos más homogéneos usando algoritmos de clustering permite estimaciones de elasticidad más específicas y precisas para cada grupo.

- 7 **Integración de Datos Externos:** Incorporar factores externos como datos de la competencia y condiciones económicas mejora la precisión del modelo al considerar un contexto más amplio.

Consulta 2

- ¿Qué algoritmos de machine learning serían más efectivos para predecir la elasticidad de la demanda en diferentes segmentos de mercado?

Respuesta:

Para predecir la elasticidad de la demanda en diferentes segmentos de mercado, los siguientes algoritmos de machine learning serían particularmente efectivos:

1. Regresión Lineal Múltiple

- Ideal para situaciones donde la relación entre la demanda y sus factores es aproximadamente lineal. Puede manejar múltiples variables predictoras para segmentar y analizar la elasticidad en diferentes mercados.

2. Árboles de Decisión y Random Forest

- **Árboles de Decisión:** Capturan relaciones no lineales y pueden manejar interacciones complejas entre variables.
- **Random Forest:** Combina múltiples árboles de decisión para mejorar la precisión y reducir el riesgo de sobreajuste, proporcionando robustez en la predicción de elasticidad para diferentes segmentos.

3. Gradient Boosting Machines (GBM)

- **XGBoost, LightGBM, y CatBoost:** Estos algoritmos son potentes para capturar relaciones no lineales y complejas. Son efectivos en la predicción de elasticidad en segmentos de mercado al mejorar la precisión de los modelos mediante el aumento de gradiente.

4. Redes Neuronales

- **Redes Neuronales Artificiales (ANN):** Son capaces de capturar patrones complejos y no lineales en los datos.
- **Redes Neuronales Recurrentes (RNN):** Especialmente útiles para datos de series temporales, proporcionando mejores predicciones de elasticidad al considerar la evolución temporal de la demanda.

5. Support Vector Machines (SVM)

- Efectivas para manejar relaciones no lineales y cuando se dispone de un número limitado de datos. Pueden segmentar el mercado mediante la identificación de fronteras de decisión complejas.

6. K-Means Clustering y DBSCAN

- Aunque no son algoritmos de predicción, estos métodos de clustering son útiles para segmentar el mercado en grupos homogéneos antes de aplicar modelos predictivos de elasticidad. Una vez segmentados, se pueden aplicar los algoritmos mencionados para cada grupo.

7. Modelos Bayesianos

- **Regresión Bayesiana:** Permite incorporar información previa y ajustar continuamente las predicciones con nuevos datos, proporcionando intervalos de confianza más precisos para la elasticidad en diferentes segmentos de mercado.

8. Ensemble Methods

- Combinan múltiples modelos para mejorar la precisión general. Los enfoques como **stacking** y **bagging** pueden ser muy efectivos para capturar la elasticidad en diversos segmentos de mercado al reducir el sesgo y la varianza.

Ejemplo de Aplicación

Para predecir la elasticidad de la demanda en diferentes segmentos de mercado, se podría primero utilizar K-Means Clustering para agrupar a los consumidores en segmentos homogéneos. Luego, se podría aplicar un modelo Random Forest o XGBoost a cada segmento para capturar las relaciones específicas entre precio y demanda. Adicionalmente, se podría emplear regresión bayesiana para actualizar continuamente las predicciones con nuevos datos, mejorando la precisión a lo largo del tiempo.

Estos algoritmos proporcionan un enfoque robusto y flexible para predecir la elasticidad de la demanda, permitiendo una adaptación precisa a las características particulares de cada segmento de mercado.

Consulta 3

- Haz un ejemplo sencillo con información ficticia de cómo sería la estimación de la elasticidad con el modelo XGBoost. Considera estimar la elasticidad de un producto y genera el resultado final de cómo calcular la elasticidad con el cambio de 1% en el precio.

Claro, aquí tienes un ejemplo sencillo de cómo estimar la elasticidad de la demanda usando XGBoost con datos ficticios y calcular la elasticidad con un cambio del 1% en el precio.

Paso 1: Generación de Datos Ficticios

Imaginemos que tenemos datos de ventas de un producto durante 12 meses, con información sobre el precio y la demanda.

	Mes	Precio	Demanda
1	10	100	
2	9	110	
3	8	130	
4	7	150	
5	6	180	
6	5	210	
7	4	240	
8	3	270	
9	4	250	
10	5	220	
11	6	190	
12	7	160	

Paso 2: Preparación de Datos

```
python
Copiar código
import pandas as pd
import xgboost as xgb
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error

# Crear un DataFrame con los datos
data = {
    'Mes': list(range(1, 13)),
    'Precio': [10, 9, 8, 7, 6, 5, 4, 3, 4, 5, 6, 7],
    'Demanda': [100, 110, 130, 150, 180, 210, 240, 270, 250, 220, 190,
160]
}

df = pd.DataFrame(data)

# Definir las características (X) y el objetivo (y)
X = df[['Mes', 'Precio']]
y = df['Demanda']

# Dividir los datos en conjuntos de entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)
```

Paso 3: Entrenamiento del Modelo XGBoost

```
python
# Crear matrices de datos para XGBoost
dtrain = xgb.DMatrix(X_train, label=y_train)
dtest = xgb.DMatrix(X_test, label=y_test)

# Definir los parámetros del modelo
params = {
    'objective': 'reg:squarederror',
    'max_depth': 3,
    'learning_rate': 0.1,
    'n_estimators': 100
}

# Entrenar el modelo
model = xgb.train(params, dtrain, num_boost_round=100)
```

Paso 4: Predicción y Evaluación

```
python
# Realizar predicciones
predictions = model.predict(dtest)

# Evaluar el modelo
mse = mean_squared_error(y_test, predictions)
print(f'Mean Squared Error: {mse}')
```

Paso 5: Cálculo de la Elasticidad

Para calcular la elasticidad de la demanda, primero necesitamos estimar la demanda con un pequeño cambio en el precio (por ejemplo, un 1% de cambio). Supongamos que queremos calcular la elasticidad para un precio específico, digamos 5.

```
python
Copiar código
import numpy as np

# Precio actual
precio_actual = 5
# Cambio de precio del 1%
nuevo_precio = precio_actual * 1.01

# Crear un DataFrame para los nuevos datos
nuevo_dato = pd.DataFrame({'Mes': [12], 'Precio': [nuevo_precio]})

# Realizar la predicción con el nuevo precio
dtest_nuevo = xgb.DMatrix(nuevo_dato)
nueva_prediccion = model.predict(dtest_nuevo)
```

```
# Demanda actual (predicha)
demanda_actual = model.predict(xgb.DMatrix(pd.DataFrame({'Mes': [12],
'Precio': [precio_actual]})))[0]

# Demanda con el nuevo precio
demanda_nueva = nueva_prediccion[0]

# Calcular el cambio porcentual en la demanda y en el precio
cambio_porcentual_demanda = (demanda_nueva - demanda_actual) /
demanda_actual * 100
cambio_porcentualPrecio = (nuevo_precio - precio_actual) / precio_actual
* 100

# Calcular la elasticidad
elasticidad = cambio_porcentual_demanda / cambio_porcentualPrecio
print(f'Elasticidad de la demanda: {elasticidad}')
```

Interpretación de Resultados

Supongamos que los cálculos dieron los siguientes resultados:

- **Demanda Actual:** 220 unidades
- **Demanda con Precio Nuevo:** 215 unidades
- **Cambio Porcentual en la Demanda:** $\frac{215-220}{220} \times 100 = -2.27\%$
- **Cambio Porcentual en el Precio:** $\frac{5.05-5}{5} \times 100 = 1\%$

La elasticidad sería:

$$\text{Elasticidad} = \frac{-2.27\%}{1\%} = -2.27$$

Este valor negativo indica que la demanda es elástica y disminuye cuando aumenta el precio. En este caso, una disminución del 1% en el precio resulta en una disminución del 2.27% en la demanda, mostrando una demanda relativamente sensible a cambios en el precio.

Comentarios finales

- **Aplicación de IA en estimación de elasticidad:** La inteligencia artificial, particularmente los modelos de machine learning y deep learning, ofrece herramientas para mejorar significativamente la precisión en la estimación de elasticidad de productos. Estas técnicas permiten analizar grandes volúmenes de datos y capturar relaciones complejas que los métodos tradicionales podrían pasar por alto.
- **Diversidad de modelos:** Existe una variedad de algoritmos aplicables a la estimación de elasticidad, desde modelos más simples como la regresión lineal múltiple hasta técnicas avanzadas como XGBoost y redes neuronales. La elección del modelo dependerá de la naturaleza de los datos y la complejidad del problema.
- **Importancia de la segmentación:** La segmentación del mercado, utilizando técnicas como K-Means Clustering, emerge como un paso crucial previo a la aplicación de modelos predictivos. Esto permite estimaciones de elasticidad más precisas y específicas para cada grupo de consumidores.
- **Integración de datos:** La incorporación de datos externos y el análisis de sentimientos mediante NLP demuestran la importancia de considerar un contexto más amplio en las estimaciones de elasticidad, mejorando la robustez de los modelos.
- **Implementación práctica:** La aplicación exitosa de estos modelos en un entorno empresarial requiere considerar aspectos como la actualización continua de datos, el reentrenamiento de modelos y la interpretación adecuada de resultados.

Referencias

- Environmental Resources Management (ERM). (2024). <https://www.erm.com/>
- Khan, F. (2023, 24 de mayo). Prompt Engineering Complete Guide. Medium. <https://medium.com/@fareedkhandev/prompt-engineering-complete-guide-2968776f0431>
- Prompting Guide. (2024). Examples. <https://www.promptingguide.ai/introduction/examples>
- Merve. (2024). ChatGPT Prompt Generator. Hugging Face. <https://huggingface.co/spaces/merve/ChatGPT-prompt-generator>
- Microsoft & OpenAI. (2024). Bing Chat [Modelo de lenguaje GPT-4]. <https://www.bing.com/chat?form=NTPCHB>
- Google. (2024). Gemini. <https://gemini.google.com/?hl=es-MX>
- OpenAI. (2024). Playground. <https://platform.openai.com/playground>